TP3 Bis : Familiarisation avec les données

Transformation de données

ATTIA Oussama Abderraouf - SIL1

12 mars 2026

Table des matières

1 Introduction **2**
1.1 Packages utilisés . . . 2

2 Dataset Iris **2**
2.1 Caractéristiques du dataset . . . 2
2.2 Analyse en Composantes Principales (ACP) . . . 2
2.2.1 Valeurs propres . . . 3
2.2.2 Nombre de composantes retenues ($\geq 80\%$) . . . 3
2.2.3 Visualisation ACP . . . 4
2.3 Clustering K-means sur les données originales . . . 5
2.3.1 Détermination du nombre optimal de clusters . . . 5
2.3.2 Résultats du clustering (k=3) . . . 7
2.3.3 Visualisation avec clusplot . . . 7
2.4 Clustering sur les composantes principales . . . 8
2.5 Sélection d'attributs . . . 9
2.6 Clustering sur les attributs sélectionnés . . . 9
2.7 Comparaison des résultats – Iris . . . 11

3 Dataset Glass **11**
3.1 Caractéristiques du dataset . . . 11
3.2 ACP sur Glass . . . 12
3.3 Clustering K-means sur Glass . . . 13
3.3.1 Méthode Elbow et Silhouette . . . 13
3.3.2 Résultats et visualisation (k=6) . . . 14
3.4 Clustering sur les composantes principales . . . 15
3.5 Sélection d'attributs sur Glass . . . 16
3.6 Clustering sur les attributs sélectionnés . . . 17
3.7 Comparaison des résultats – Glass . . . 18

4 Comparaison générale et conclusion **18**
4.1 Temps d'exécution . . . 18
4.2 Conclusion . . . 19

1 Introduction

L'objectif de ce TP est de se familiariser avec les techniques de transformation de données. On va travailler avec l'Analyse en Composantes Principales (ACP), le clustering K-means, et la sélection d'attributs. On utilise deux jeux de données : **Iris** et **Glass**.

1.1 Packages utilisés

```r
library(FactoMineR)    # ACP
library(factoextra)    # Visualisation
library(cluster)       # Clusplot
library(FSelector)     # Selection d'attributs
library(mlbench)       # Dataset Glass
```

2 Dataset Iris

2.1 Caractéristiques du dataset

```r
data(iris)
dim(iris)
# [1] 150   5
summary(iris)
```

Le dataset Iris contient **150 observations** et **5 variables** : 4 variables numériques (Sepal.Length, Sepal.Width, Petal.Length, Petal.Width) et 1 variable catégorielle (Species avec 3 classes : setosa, versicolor, virginica).

2.2 Analyse en Composantes Principales (ACP)

On applique l'ACP sur les 4 variables numériques du dataset Iris.

```r
library(FactoMineR)
T1 <- Sys.time()
acp_iris <- PCA(iris_num, graph = FALSE)
T2 <- Sys.time()
T2 - T1
```

2.2.1 Valeurs propres

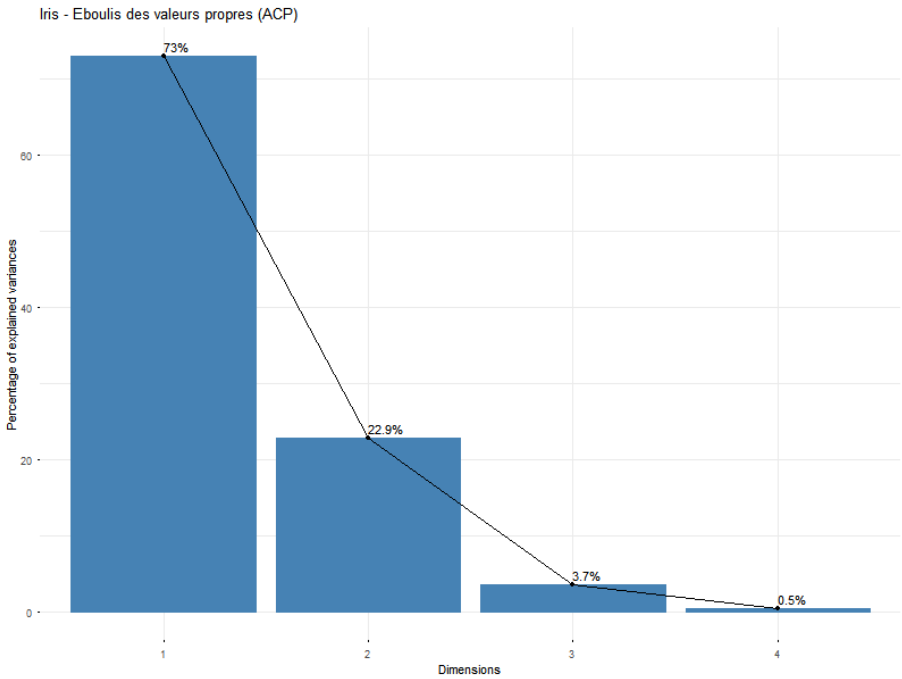

FIGURE 1 – Iris – Éboulis des valeurs propres (ACP)

Les deux premières composantes principales expliquent exactement **95.81%** de la variance totale. La première composante seule capture 72.96% de l'information.

2.2.2 Nombre de composantes retenues ($\geq$ 80%)

On retient les composantes qui couvrent au moins 80% de la variance. Pour Iris, **2 composantes** suffisent (cumul $\approx$ 95.8%).

2.2.3 Visualisation ACP

FIGURE 2 – Iris – Plan des individus (ACP)

On voit que les trois espèces sont bien séparées sur le plan principal. Setosa est clairement distincte, tandis que Versicolor et Virginica se chevauchent légèrement.

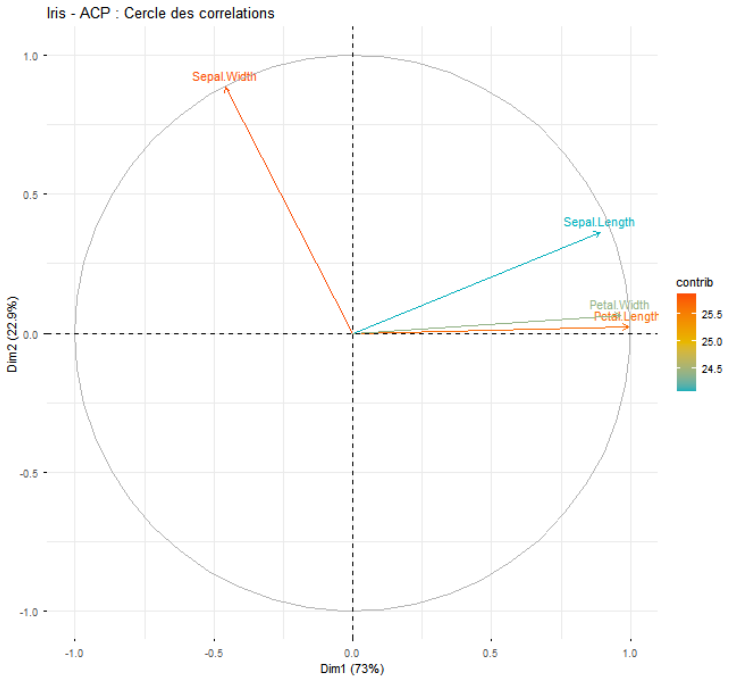

FIGURE 3 – Iris – Cercle des corrélations (ACP)

Le cercle des corrélations montre que Petal.Length et Petal.Width sont fortement corrélées entre elles et contribuent beaucoup à la première composante.

2.3 Clustering K-means sur les données originales

2.3.1 Détermination du nombre optimal de clusters

Méthode Elbow :

```
library(factoextra)
fviz_nbclust(iris_scaled, kmeans, method = "wss")
```

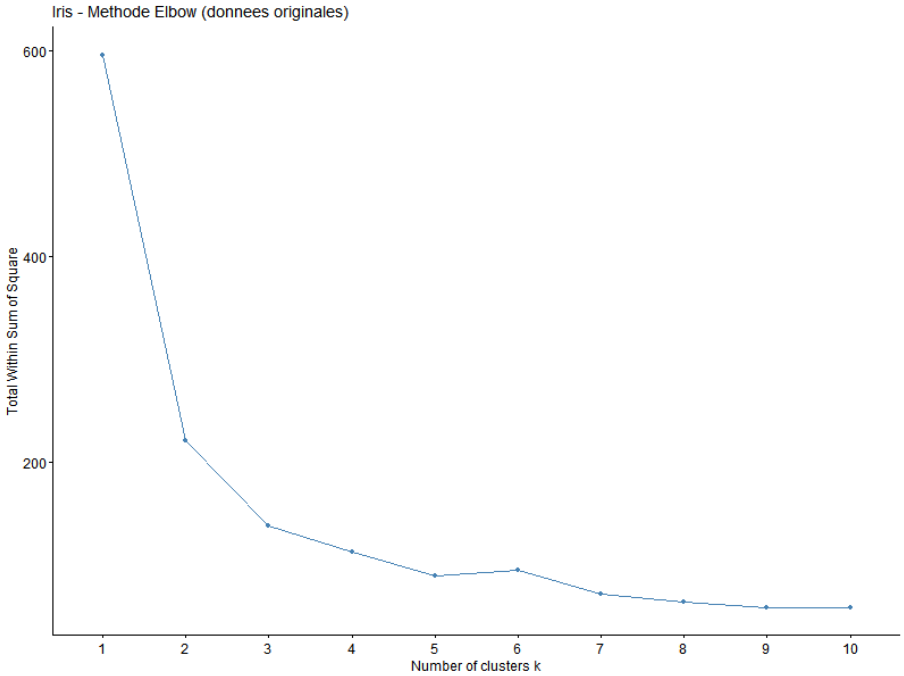

FIGURE 4 – Iris – Méthode Elbow (données originales)

On peut aussi utiliser la méthode manuelle :

```
k.max <- 10
wss <- sapply(1:k.max, function(k){
  kmeans(iris_scaled, k, nstart=50, iter.max=15)$tot.withinss
})
plot(1:k.max, wss, type="b", pch=19, frame=FALSE,
     xlab="Number of clusters K",
     ylab="Total within-clusters sum of squares")
```

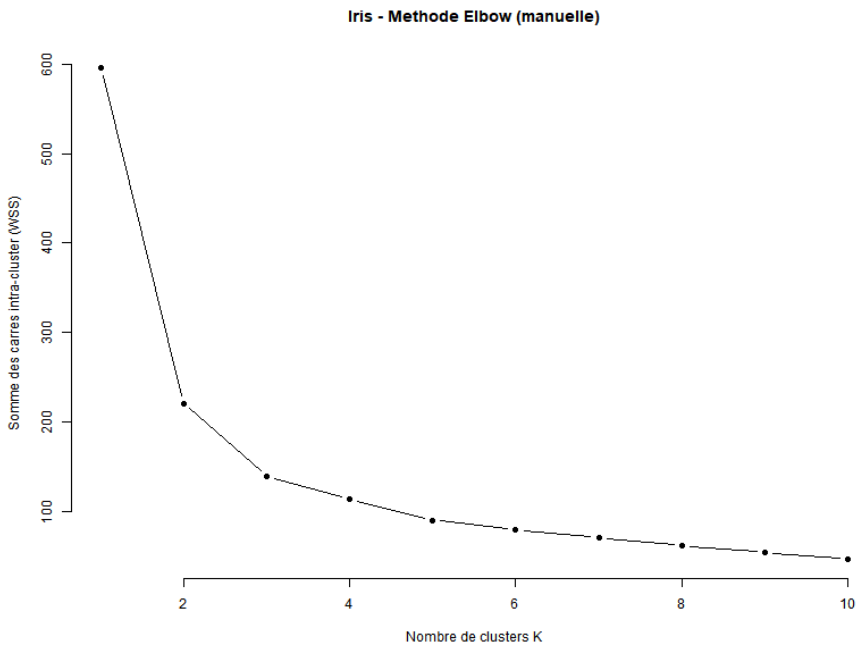

FIGURE 5 – Iris – Méthode Elbow manuelle

Le coude est visible à **k=3**, ce qui correspond aux 3 espèces du dataset.

Méthode Silhouette :

```
fviz_nbclust(iris_scaled, kmeans, method = "silhouette")
```

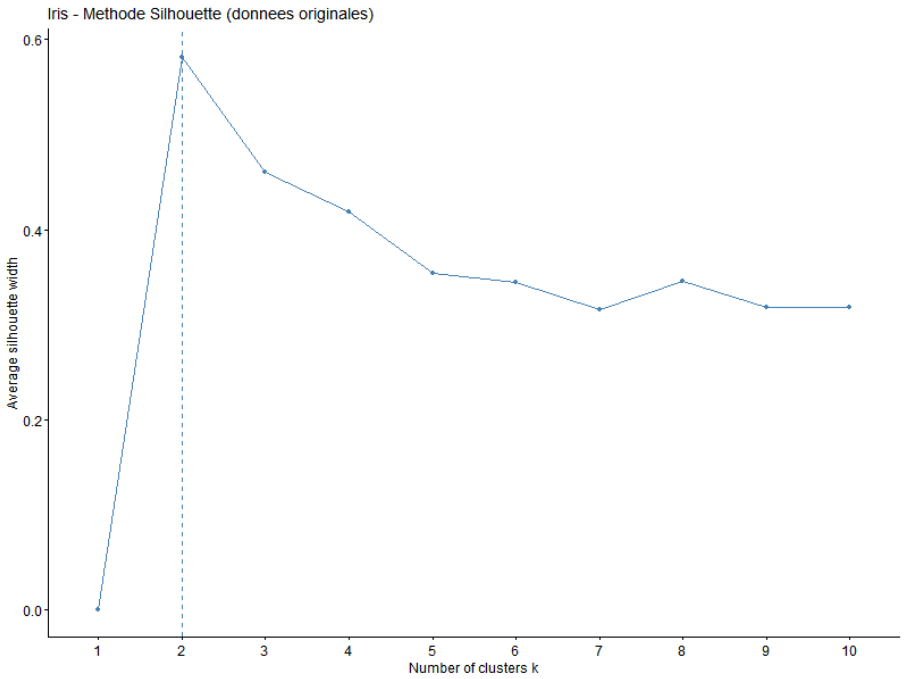

FIGURE 6 – Iris – Méthode Silhouette (nombre optimal)

La méthode Silhouette confirme également **k=2 ou k=3** comme nombre optimal.

2.3.2 Résultats du clustering (k=3)

```
km_iris <- kmeans(iris_scaled, centers=3, nstart=50)
```

Le clustering avec k=3 donne un ratio BSS/TSS de **76.7%**, ce qui signifie que les clusters captent une bonne partie de la variance. Le score silhouette moyen est d'environ **0.46**.

2.3.3 Visualisation avec clusplot

```
library(cluster)
clusplot(iris_scaled, km_iris$cluster,
         color=TRUE, shade=TRUE, labels=2, lines=0)
```

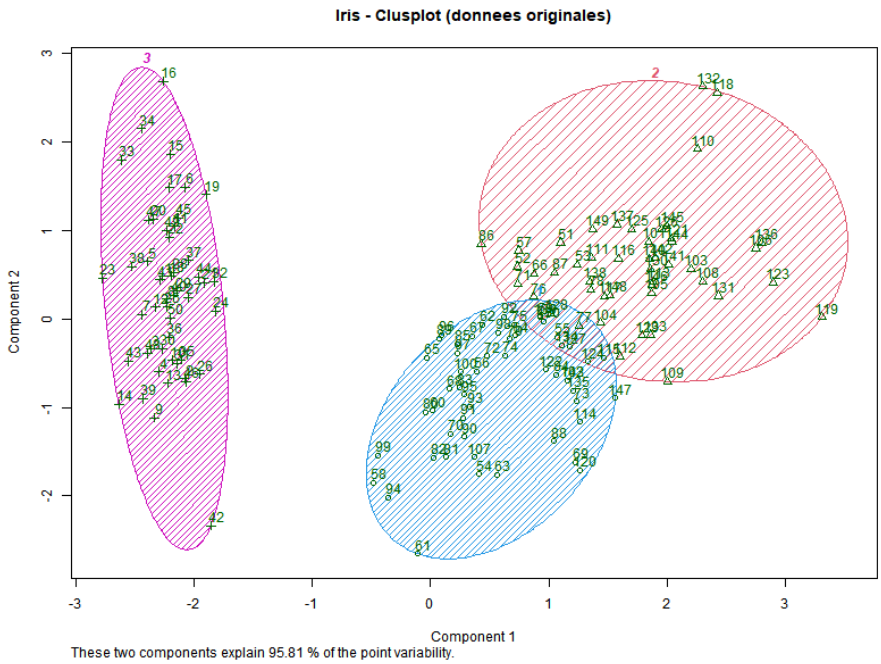

FIGURE 7 – Iris – Clusplot (données originales)

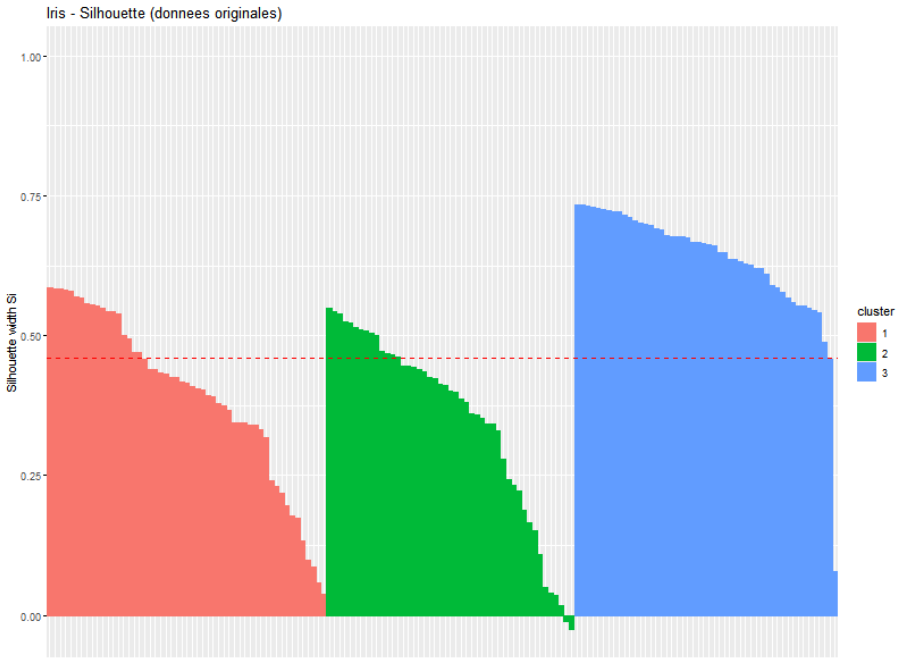

FIGURE 8 – Iris – Silhouette (données originales)

2.4 Clustering sur les composantes principales

On refait le K-means sur les composantes principales extraites (2 composantes couvrant $\geq 80\%$).

```
iris_pca_data <- acp_iris$ind$coord[, 1:2]
km_iris_pca <- kmeans(iris_pca_data, centers=3, nstart=50)
```

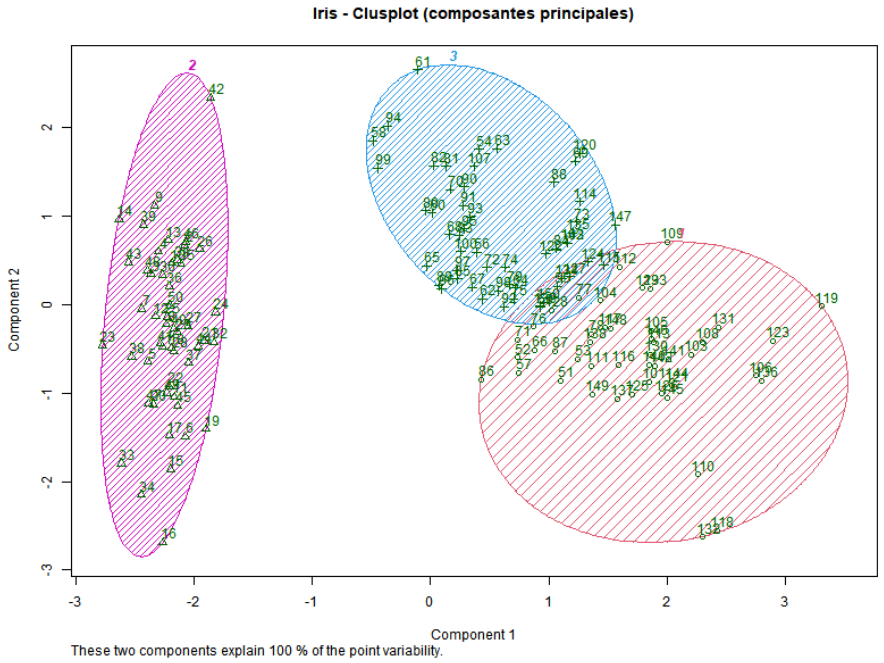

FIGURE 9 – Iris – Clusplot (composantes principales)

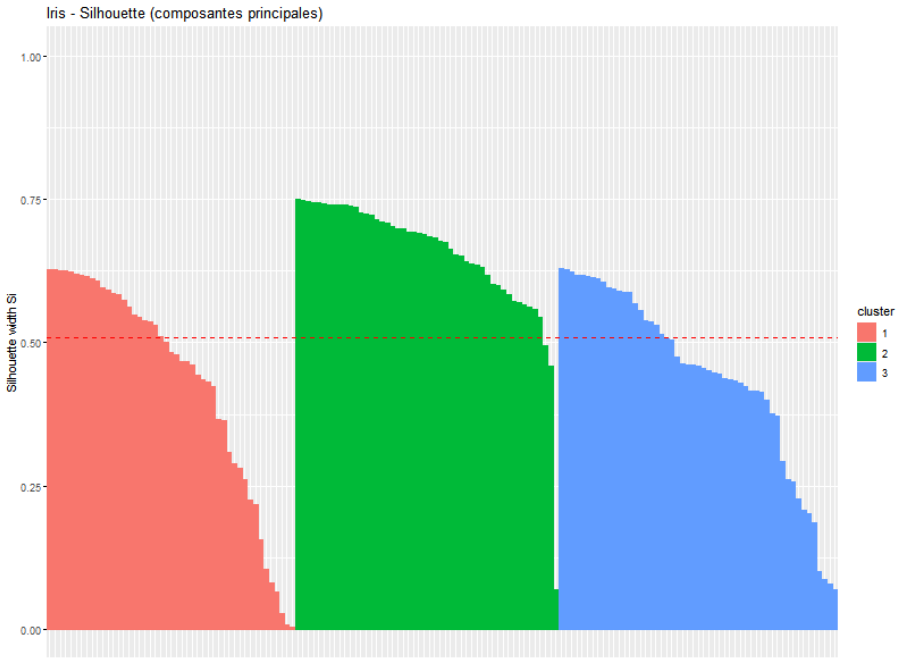

FIGURE 10 – Iris – Silhouette (composantes principales)

2.5 Sélection d'attributs

On utilise la méthode CFS (Correlation-based Feature Selection) pour sélectionner les attributs les plus pertinents.

```
library(FSelector)
result <- cfs(Species ~ ., iris)
result
f <- as.simple.formula(result, "Species")
```

Les attributs sélectionnés par CFS sont : **Petal.Length** et **Petal.Width**. Ce résultat est cohérent avec l'ACP où ces variables contribuaient le plus à la première composante.

2.6 Clustering sur les attributs sélectionnés

```
iris_selected <- iris[, result]
iris_selected_scaled <- scale(iris_selected)
km_iris_selected <- kmeans(iris_selected_scaled, centers=3, nstart
    =50)
```

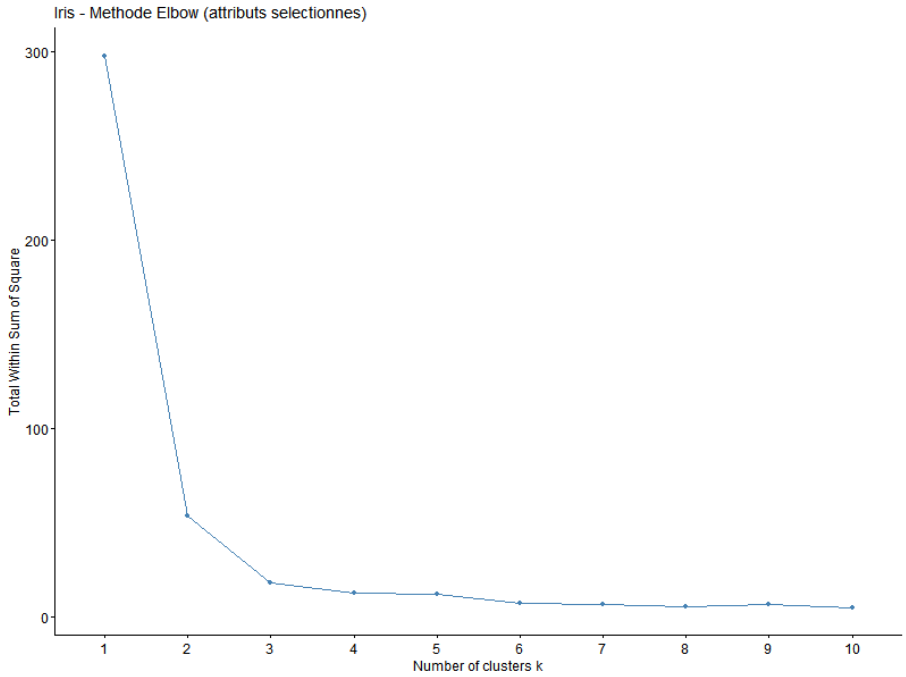

FIGURE 11 – Iris – Méthode Elbow (attributs sélectionnés)

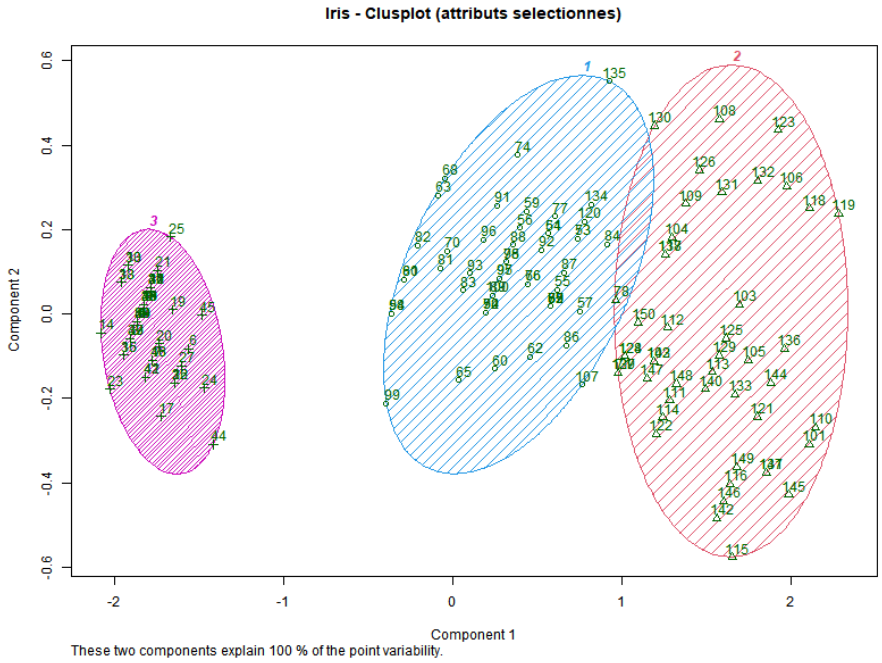

FIGURE 12 – Iris – Clusplot (attributs sélectionnés)

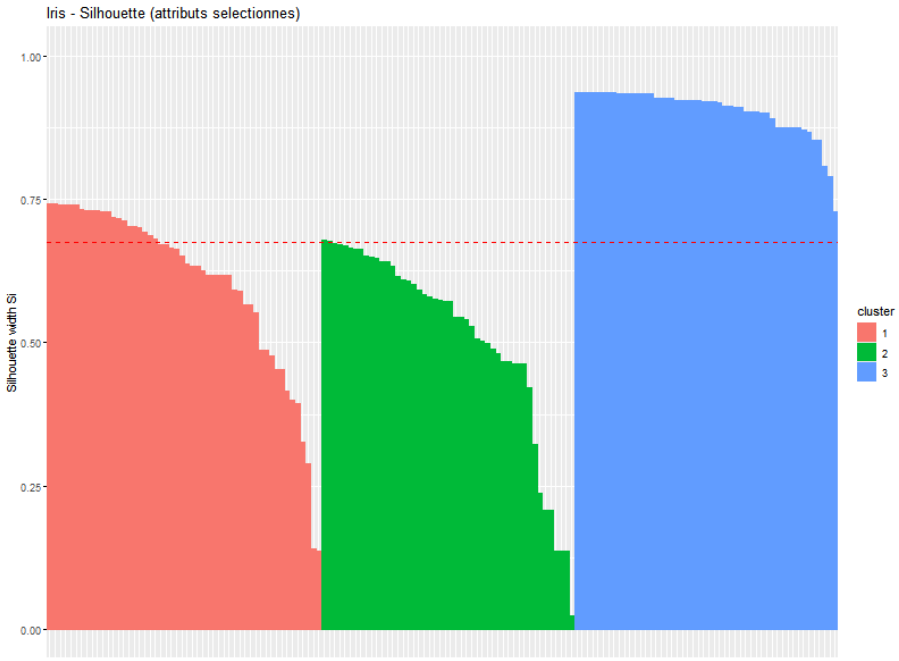

FIGURE 13 – Iris – Silhouette (attributs sélectionnés)

2.7 Comparaison des résultats – Iris

TABLE 1 – Comparaison des méthodes de clustering sur Iris

Méthode	**WSS**	**BSS/TSS**	**Silhouette**
Données originales	138.89	0.7670	0.4599
Composantes principales	115.02	0.7999	0.5092
Attributs sélectionnés	17.91	0.9399	0.6741

Interprétation : Le clustering sur les attributs sélectionnés (*Petal.Length*, *Petal.Width*) donne le meilleur score de silhouette (**0.67**), ce qui montre que ces deux variables suffisent amplement à séparer les espèces d'Iris de manière très distincte.

3 Dataset Glass

3.1 Caractéristiques du dataset

```
data(Glass) # package mlbench
dim(Glass)
# [1] 214  10
summary(Glass)
```

Le dataset Glass contient **214 observations** et **10 variables** : 9 variables numériques (RI, Na, Mg, Al, Si, K, Ca, Ba, Fe) et 1 variable catégorielle (Type avec 6 classes).

3.2 ACP sur Glass

```
acp_glass <- PCA(glass_num, graph = FALSE)
```

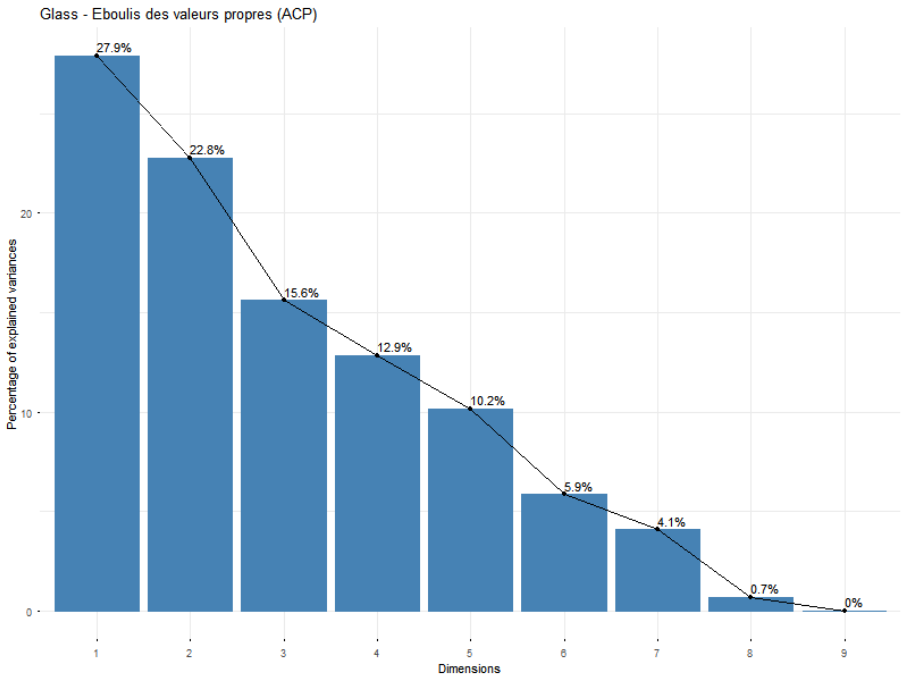

FIGURE 14 – Glass – Éboulis des valeurs propres (ACP)

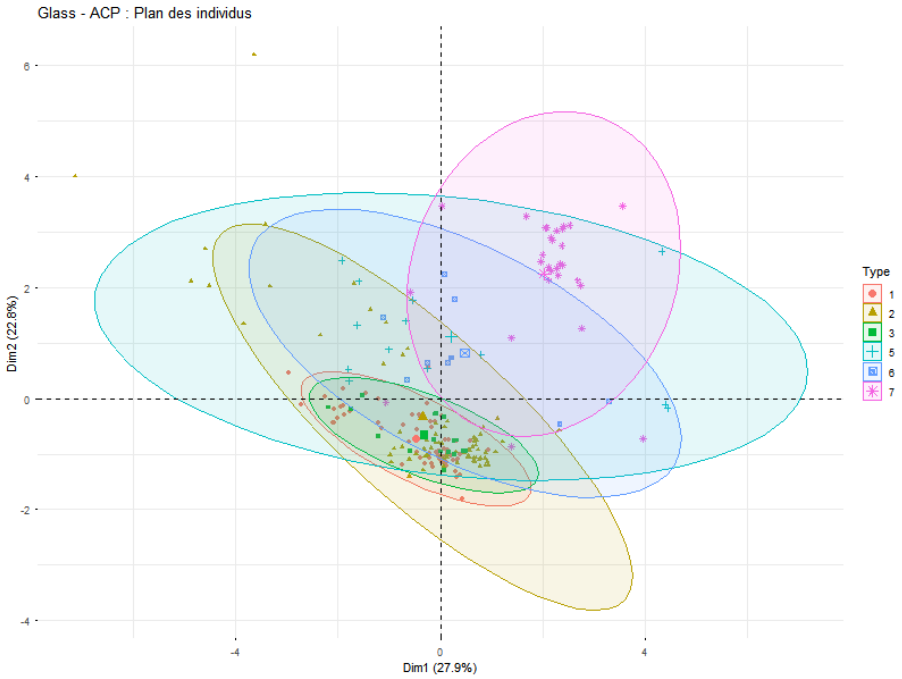

FIGURE 15 – Glass – Plan des individus (ACP)

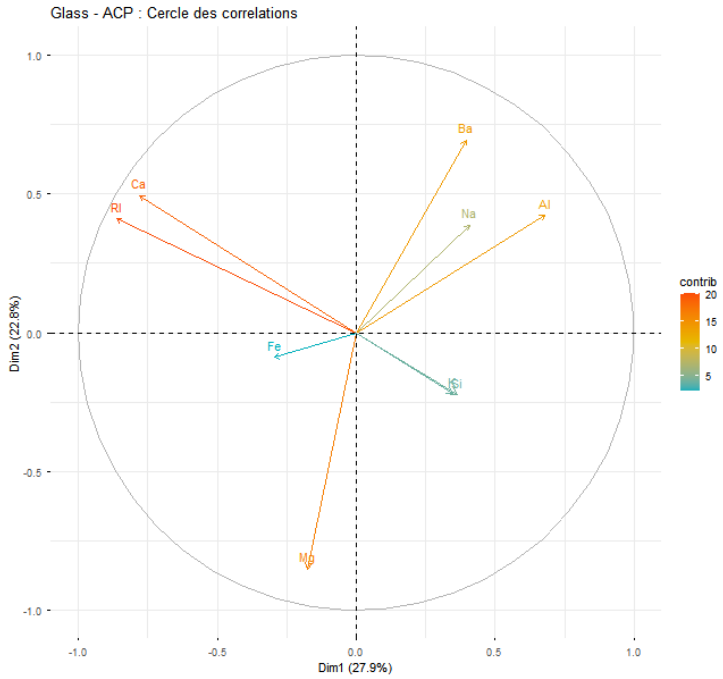

FIGURE 16 – Glass – Cercle des corrélations (ACP)

Pour Glass, il faut plus de composantes pour atteindre 80% de la variance (environ 5–6 composantes), car les variables sont moins corrélées que dans Iris.

3.3 Clustering K-means sur Glass

3.3.1 Méthode Elbow et Silhouette

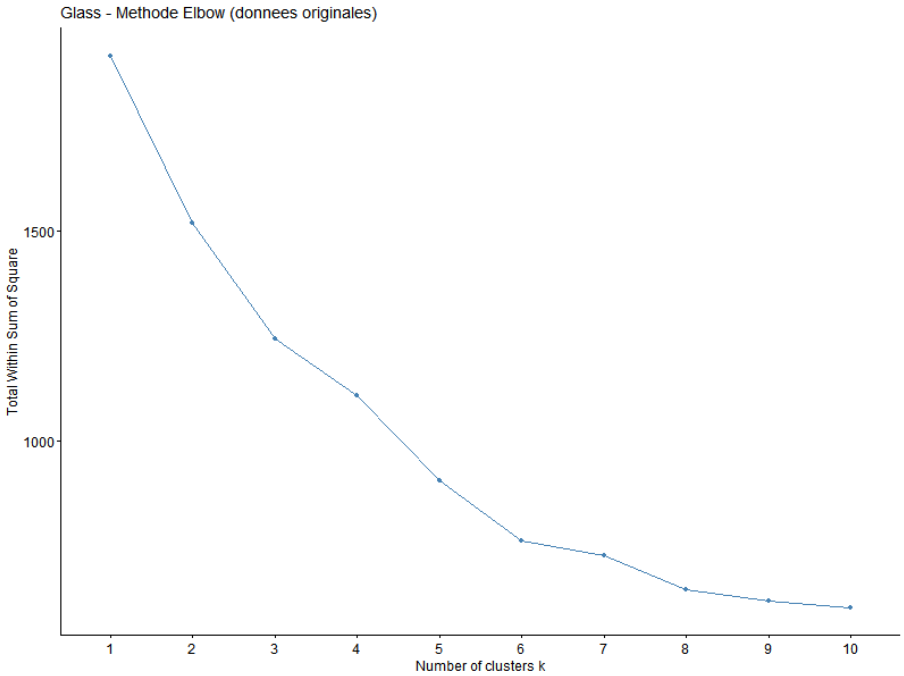

FIGURE 17 – Glass – Méthode Elbow (données originales)

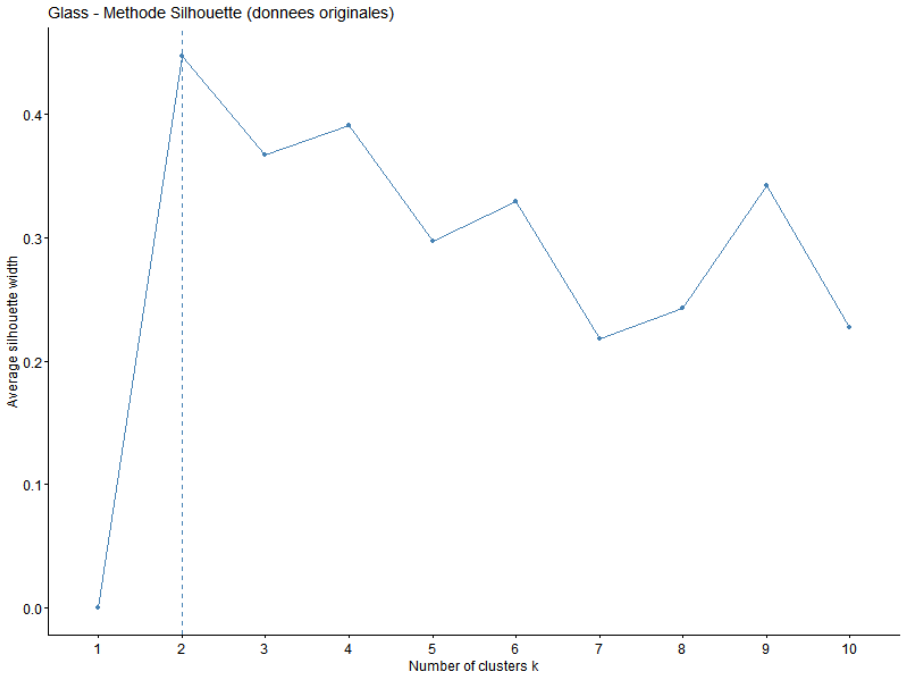

FIGURE 18 – Glass – Méthode Silhouette (données originales)

3.3.2 Résultats et visualisation (k=6)

```
km_glass <- kmeans(glass_scaled, centers=6, nstart=50)
clusplot(glass_scaled, km_glass$cluster,
         color=TRUE, shade=TRUE, labels=2, lines=0)
```

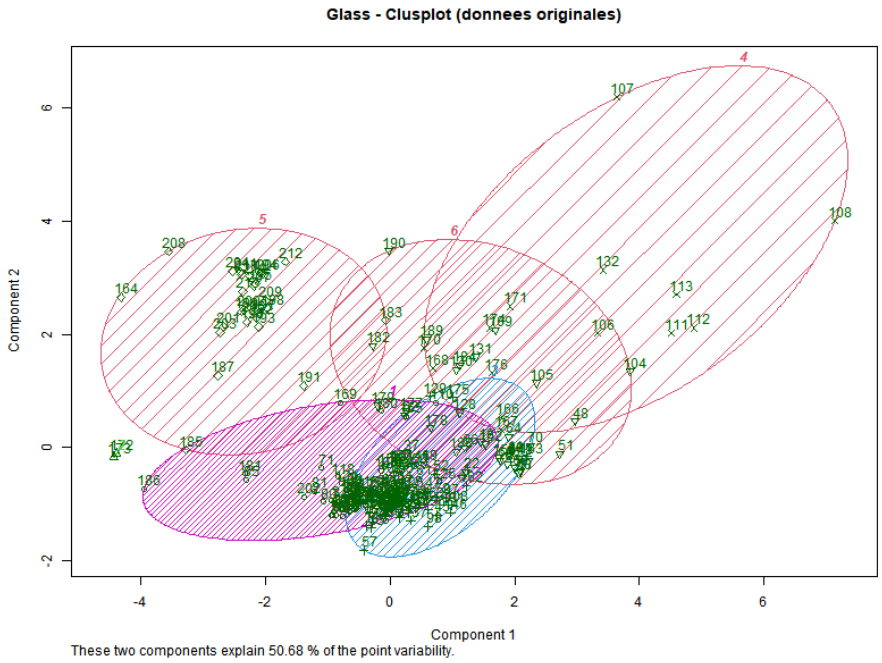

FIGURE 19 – Glass – Clusplot (données originales)

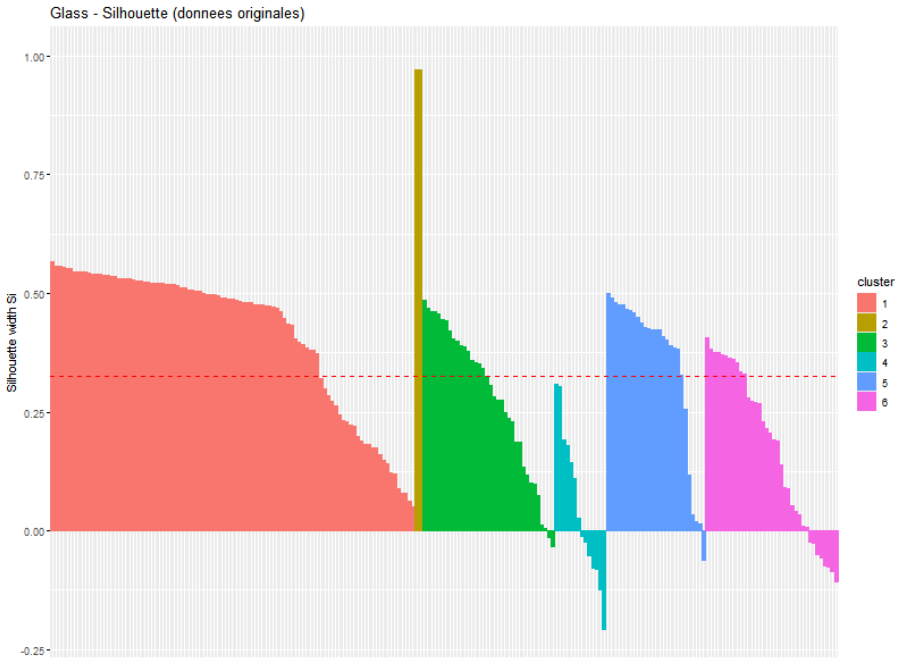

FIGURE 20 – Glass – Silhouette (données originales)

3.4 Clustering sur les composantes principales

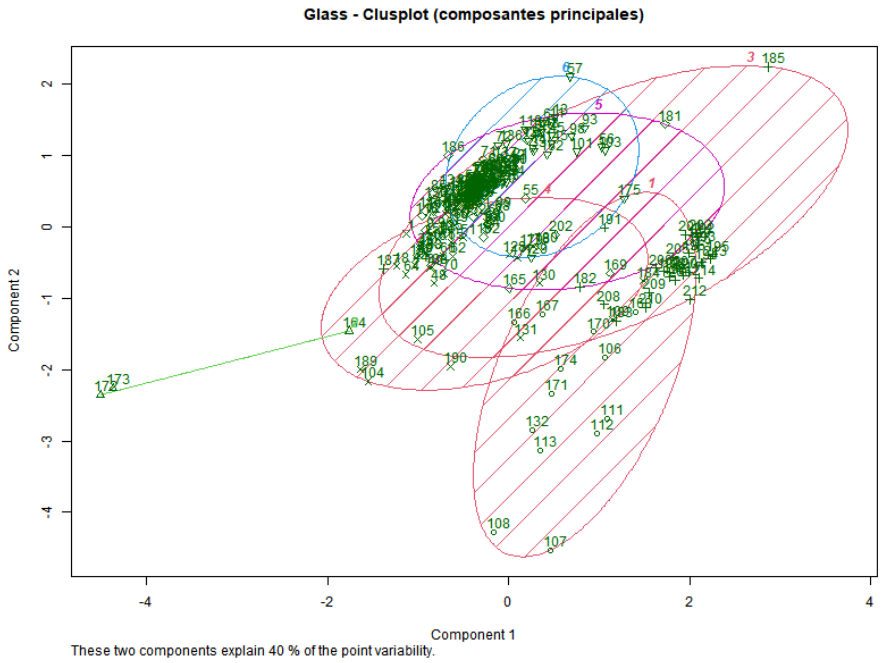

FIGURE 21 – Glass – Clusplot (composantes principales)

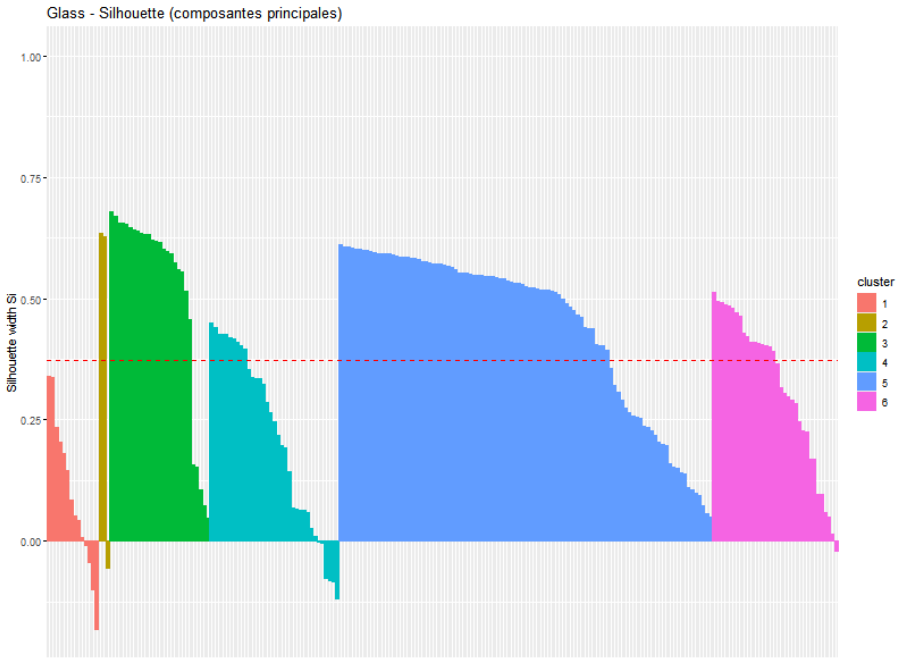

FIGURE 22 – Glass – Silhouette (composantes principales)

3.5 Sélection d'attributs sur Glass

```
result_glass <- cfs(Type ~ ., Glass)
result_glass
f_glass <- as.simple.formula(result_glass, "Type")
```

Les attributs sélectionnés par CFS pour Glass sont : **Mg**, **Al**, **K**, **Ca**, **Ba**.

3.6 Clustering sur les attributs sélectionnés

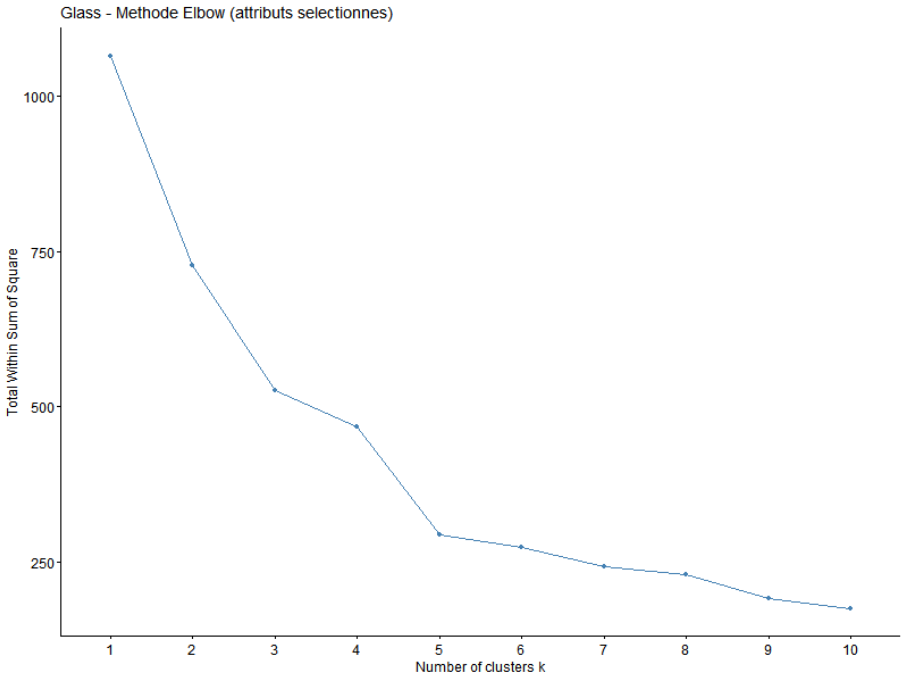

FIGURE 23 – Glass – Méthode Elbow (attributs sélectionnés)

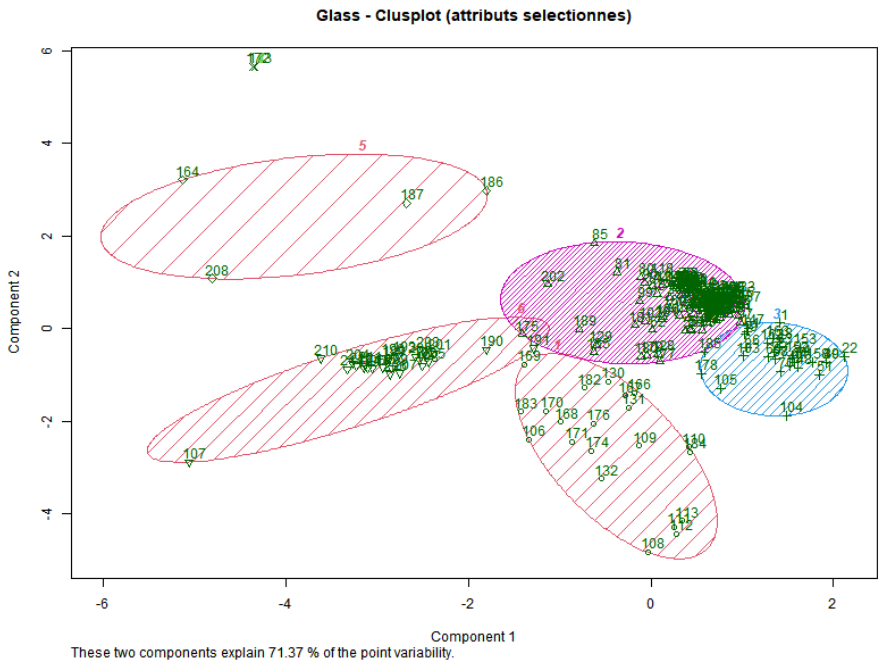

FIGURE 24 – Glass – Clusplot (attributs sélectionnés)

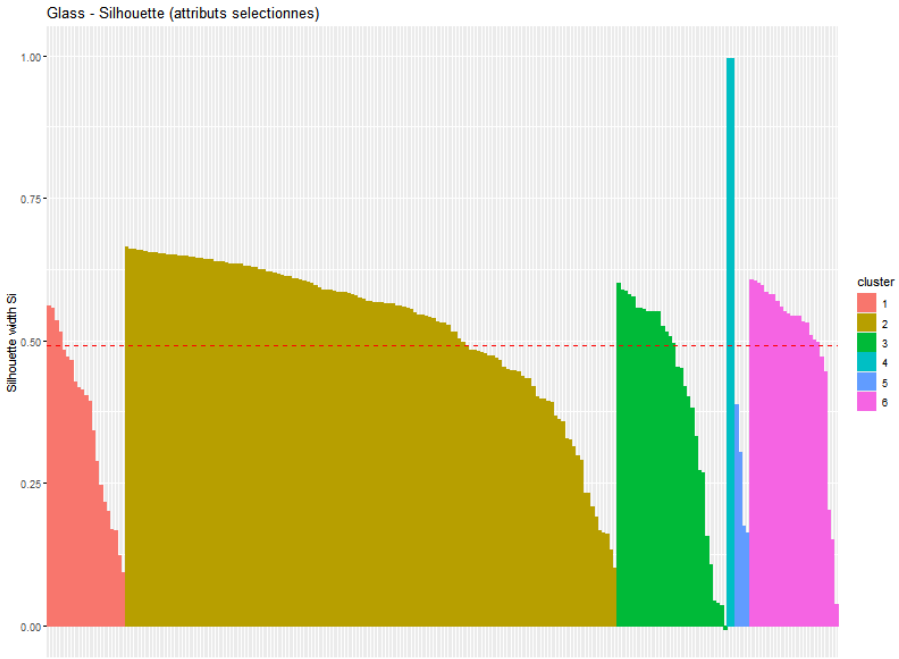

FIGURE 25 – Glass – Silhouette (attributs sélectionnés)

3.7 Comparaison des résultats – Glass

TABLE 2 – Comparaison des méthodes de clustering sur Glass

Méthode	**WSS**	**BSS/TSS**	**Silhouette**
Données originales	762.83	0.6021	0.3247
Composantes principales	586.19	0.6592	0.3723
Attributs sélectionnés	242.72	0.7721	0.4905

Interprétation : Le clustering sur Glass est plus difficile. Cependant, la sélection d'attributs améliore significativement le score de silhouette (de 0.32 à **0.49**), tout en augmentant le ratio BSS/TSS.

4 Comparaison générale et conclusion

4.1 Temps d'exécution

```
T1 <- Sys.time()
# code R
T2 <- Sys.time()
T2 - T1
```

La sélection d'attributs et la réduction de dimensions permettent de réduire le temps de calcul, surtout pour les grands datasets.

4.2 Conclusion

- **ACP** : Permet de réduire la dimensionnalité tout en conservant la majorité de l'information. Pour Iris, 2 composantes suffisent (95.8%). Pour Glass, il en faut plus.
- **K-means** : La méthode Elbow et Silhouette aident à déterminer le nombre optimal de clusters. Pour Iris, k=3 est optimal.
- **Clustering sur PCA vs Original** : Les résultats sont similaires quand l'ACP conserve assez de variance.
- **Sélection d'attributs (CFS)** : Permet de réduire le nombre de variables tout en conservant la qualité du clustering.
- **Iris vs Glass** : Iris est plus facile à clusteriser car ses classes sont mieux séparées. Glass est plus complexe avec plus de chevauchement entre les types.